Fundamentos Matemáticos del Aprendizaje por Refuerzo

Capítulo 1 — Marco Teórico (basado en Sutton & Barto)

Prof. Julián Fernando Sánchez
Semillero de Aprendizaje por Refuerzo
Programa de Ciencia de Datos
Universidad Externado de Colombia

2 de septiembre de 2025

Resumen

Este capítulo presenta un desarrollo riguroso del marco matemático del Aprendizaje por Refuerzo (RL), con énfasis en Procesos de Decisión de Markov (MDP), funciones de valor, operadores de Bellman, y algoritmos clásicos de iteración de valores y de políticas. El tratamiento sigue de cerca a *Reinforcement Learning: An Introduction* de Sutton y Barto (2018), adaptándolo al contexto del Semillero de Aprendizaje por Refuerzo del Programa de Ciencia de Datos de la Universidad Externado de Colombia.

Índice

1. Introducción **2**

2. Preliminares y notación **2**

3. Procesos de Decisión de Markov (MDP) **3**

4. Retorno y funciones de valor **3**

5. Operadores de Bellman y contracción **4**

6. Optimalidad **5**

7. Evaluación de políticas e iteración de políticas **5**
7.1. Evaluación iterativa de π 5
7.2. Teorema de mejora de política 6
7.3. Iteración de políticas 6

8. Iteración de valores **7**

9. Variantes de criterio: retorno promedio **7**

10. Extensiones y adelanto: aprendizaje sin modelo y aproximación **8**
10.1. TD(0) y Q-learning (esbozo) 8
10.2. Estados/acciones continuos y aproximadores 8

11. Buenas prácticas y consideraciones empíricas **8**

1. Introducción

El Aprendizaje por Refuerzo (RL, por sus siglas en inglés) estudia agentes que aprenden a tomar decisiones secuenciales mediante interacción con un entorno. Matemáticamente, modelamos esta interacción como un Proceso de Decisión de Markov (MDP), lo que permite formalizar objetivos, políticas y nociones de optimalidad. En este capítulo establecemos la base teórica: definimos MDPs, políticas, retorno, funciones de valor, ecuaciones de Bellman y teoremas de contracción que garantizan existencia y unicidad de soluciones. Además, se presentan algoritmos fundamentales (iteración de valores y de políticas), que constituyen el punto de partida para métodos más avanzados (p. ej., TD-learning y Q-learning), tratados al final como adelanto.

2. Preliminares y notación

Trabajaremos principalmente con espacios de estados y acciones finitos. Denotamos por $\mathcal{S}$ el conjunto finito de estados y por $\mathcal{A}$ el conjunto finito de acciones. Un tiempo discreto $t \in \mathbb{N}$ indexa la evolución del sistema. Emplearemos la notación estándar de [1].

- $S_t \in \mathcal{S}$: estado en el tiempo t.
- $A_t \in \mathcal{A}$: acción elegida en el tiempo t.
- $R_{t+1} \in \mathbb{R}$: recompensa recibida tras transicionar de S_t a S_{t+1} al ejecutar A_t.

- $\gamma \in [0, 1)$: factor de descuento.
- $\pi(a \mid s)$: política (estocástica), probabilidad de actuar con a en s.

Comentario 2.1 (Consideraciones de medida). En espacios continuos, el análisis requiere *espacios medibles* y *kernels de transición* (Markov). En este capítulo nos enfocamos en el caso finito para enfatizar ideas fundamentales sin carga técnica adicional; comentarios sobre el caso continuo se dan en §10.

3. Procesos de Decisión de Markov (MDP)

Definición 3.1 (MDP finito)**.** Un MDP finito es una tupla $\langle \mathcal{S}, \mathcal{A}, P, r, \gamma \rangle$ donde:

I) $\mathcal{S}$ es un conjunto finito de estados y $\mathcal{A}$ un conjunto finito de acciones.

II) $P(s' \mid s, a)$ son probabilidades de transición que satisfacen $\sum_{s' \in \mathcal{S}} P(s' \mid s, a) = 1$ para todo (s, a).

III) $r(s, a) = \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a]$ es la recompensa esperada inmediata.

IV) $\gamma \in [0, 1)$ es el factor de descuento.

Definición 3.2 (Propiedad de Markov)**.** El proceso satisface la propiedad de Markov si

$$\mathbb{P}\{S_{t+1} = s', R_{t+1} = r \mid S_0, A_0, \ldots, S_t, A_t\} = \mathbb{P}\{S_{t+1} = s', R_{t+1} = r \mid S_t, A_t\}.$$

Una *política* π especifica $\pi(a \mid s) \in [0, 1]$ con $\sum_{a \in \mathcal{A}} \pi(a \mid s) = 1$. Consideraremos típicamente políticas *estacionarias* (independientes de t).

4. Retorno y funciones de valor

El objetivo del agente bajo descuento es maximizar el **retorno** esperado

$$G_t \;=\; \sum_{k=0}^{\infty} \gamma^k R_{t+1+k}.$$

Definición 4.1 (Funciones de valor bajo π)**.** Para una política π:

$$v_\pi(s) := \mathbb{E}_\pi\Big[G_t \mid S_t = s\Big], \tag{1}$$

$$q_\pi(s, a) := \mathbb{E}_\pi\Big[G_t \mid S_t = s, A_t = a\Big]. \tag{2}$$

Las ecuaciones de **Bellman de expectativa** para v_π y q_π son:

$$v_\pi(s) = \sum_a \pi(a \mid s)\Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a)\, v_\pi(s')\Big], \tag{3}$$

$$q_\pi(s,a) = r(s,a) + \gamma \sum_{s'} P(s'|s,a) \sum_{a'} \pi(a'|s')\, q_\pi(s',a'). \tag{4}$$

En forma vectorial, si denotamos por $\mathbf{v}_\pi \in \mathbb{R}^{|\mathcal{S}|}$ y definimos la matriz de transición inducida por π como $(P_\pi)(s,s') = \sum_a \pi(a \mid s) P(s' \mid s,a)$, y el vector de recompensas $\mathbf{r}_\pi(s) = \sum_a \pi(a \mid s) r(s,a)$, entonces

$$\mathbf{v}_\pi = \mathbf{r}_\pi + \gamma P_\pi\, \mathbf{v}_\pi, \tag{5}$$

cuya solución existe y es única dado que $\|\gamma P_\pi\|_\infty \le \gamma < 1$.

5. Operadores de Bellman y contracción

Definimos el **operador de Bellman** asociado a π:

$$(T_\pi v)(s) \;:=\; \sum_a \pi(a \mid s)\Big[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a)\, v(s')\Big]. \tag{6}$$

Proposición 5.1 (Contracción de T_π)**.** *Para cualquier $v, w \in \mathbb{R}^{|\mathcal{S}|}$, $\|T_\pi v - T_\pi w\|_\infty \le \gamma\, \|v - w\|_\infty$.*

Demostración (boceto). Por linealidad parcial y convexidad de la suma ponderada por probabilidades,

$$\begin{aligned}
|(T_\pi v)(s) - (T_\pi w)(s)| &= \Big|\sum_a \pi(a|s)\gamma \sum_{s'} P(s'|s,a)\,[v(s') - w(s')]\Big| \\
&\le \gamma \sum_a \pi(a|s) \sum_{s'} P(s'|s,a)\, \|v - w\|_\infty \\
&= \gamma \|v - w\|_\infty.
\end{aligned}$$

Tomando supremo en s se obtiene el resultado. □

[Existencia y unicidad] Para cada π, T_π tiene un único punto fijo v_π, y la iteración $v^{(k+1)} = T_\pi v^{(k)}$ converge a v_π para cualquier $v^{(0)}$.

6. Optimalidad

La **función de valor óptima** y su análoga de acción son

$$v^*(s) := \sup_\pi v_\pi(s), \qquad\qquad q^*(s,a) := \sup_\pi q_\pi(s,a). \tag{7}$$

Definimos el operador de Bellman de *optimalidad*:

$$(Tv)(s) := \operatorname*{máx}_{a\in\mathcal{A}} \Big[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v(s') \Big]. \tag{8}$$

Teorema 6.1 (Ecuación de Bellman de optimalidad)**.** *El valor óptimo v^* es el único punto fijo de T, y T es una contracción con módulo γ en norma supremo.*

Idea de la demostración. La contracción se prueba como en §5, cambiando la media ponderada por el operador máx, que también es no expansivo. Unicidad y existencia se deducen por el teorema del punto fijo de Banach. □

Una política π^* es óptima si y sólo si es *codiciosa* con respecto a v^*: para todo s, $\pi^*(\cdot|s)$ asigna probabilidad 1 a alguna acción en el $\arg\max$ de la ecuación anterior.

7. Evaluación de políticas e iteración de políticas

7.1. Evaluación iterativa de π

Dados r, P y π, podemos aproximar v_π iterando

$$v^{(k+1)}(s) \leftarrow (T_\pi v^{(k)})(s), \qquad \forall s \in \mathcal{S}, \tag{9}$$

con criterio de parada $\|v^{(k+1)} - v^{(k)}\|_\infty < \varepsilon$.

Algorithm 1 Evaluación de política (iterativa)

Entrada: MDP $\langle \mathcal{S}, \mathcal{A}, P, r, \gamma \rangle$, política π, tolerancia ε.
Inicializar $v \leftarrow 0$.
repeat
    for cada $s \in \mathcal{S}$ **do**
        $v_{\text{nuevo}}(s) \leftarrow \sum_a \pi(a|s) \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v(s') \right]$
    end for
    $\delta \leftarrow \|v_{\text{nuevo}} - v\|_\infty$; $v \leftarrow v_{\text{nuevo}}$
until $\delta < \varepsilon$
Salida: v (aprox. de v_π).

7.2. Teorema de mejora de política

Teorema 7.1 (Mejora de política)**.** *Sea π una política y defínase una política codiciosa π' respecto de q_π: $\pi'(s) \in \arg\max_a q_\pi(s,a)$ para todo s. Entonces $v_{\pi'}(s) \geq v_\pi(s)$ para todo s, con igualdad si y sólo si π ya es óptima.*

Boceto. De la definición de q_π y el *principio de optimalidad* se obtiene que actuar codiciosamente respecto de q_π no puede empeorar el valor esperado. La prueba formal usa inducción sobre el horizonte y/o el operador de Bellman de política fija. □

7.3. Iteración de políticas

La *iteración de políticas* alterna evaluación aproximada de π y mejora codiciosa:

Algorithm 2 Iteración de políticas

Entrada: MDP, tolerancias ε.
Inicializar una política π arbitraria.
repeat
    Evaluar aproximadamente v_π (Algoritmo 1).
    Para cada s, $\pi(s) \leftarrow \arg\max_a \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v_\pi(s') \right]$.
until política estable
Salida: π óptima y v_π.

8. Iteración de valores

La *iteración de valores* aplica directamente el operador de optimalidad T:

$$v^{(k+1)}(s) \leftarrow \operatorname*{máx}_a \Big[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v^{(k)}(s') \Big]. \tag{10}$$

Algorithm 3 Iteración de valores

Entrada: MDP, tolerancia ε.
Inicializar $v \leftarrow 0$.
repeat
    $\delta \leftarrow 0$
    for cada $s \in \mathcal{S}$ **do**
        old $\leftarrow v(s)$
        $v(s) \leftarrow \text{máx}_a \Big[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v(s') \Big]$
        $\delta \leftarrow \text{máx}\{\delta, |\text{old} - v(s)|\}$
    end for
until $\delta < \varepsilon$
Recuperar una política codiciosa: $\pi(s) \in \arg\max_a \Big[r(s,a) + \gamma \sum_{s'} P(s'|s,a)\, v(s') \Big]$.

Cotas de error y criterio de parada. Dado que T es γ-contractivo en $\|\cdot\|_\infty$, la sucesión $v^{(k)}$ converge a v^*. Si $\|v^{(k+1)} - v^{(k)}\|_\infty < \varepsilon$, entonces $\|v^{(k)} - v^*\|_\infty \leq \varepsilon \frac{\gamma}{1-\gamma}$. Para obtener una política ε-óptima es común usar un umbral proporcional a $(1-\gamma)\,\varepsilon$.

9. Variantes de criterio: retorno promedio

En tareas continuas sin descuento, puede considerarse el criterio de *retorno promedio por paso* $\rho(\pi) = \lim_{n\to\infty} \frac{1}{n} \mathbb{E}_\pi \Big[\sum_{t=1}^{n} R_t \Big]$, sujeto a condiciones ergódicas. Este capítulo se concentra en el caso con descuento, más general y estable numéricamente.

10. Extensiones y adelanto: aprendizaje sin modelo y aproximación

10.1. TD(0) y Q-learning (esbozo)

En problemas sin modelo completo de P y r, surgen métodos *libres de modelo*. Dos ejemplos clásicos:

$$\text{TD(0):} \quad V(S_t) \leftarrow V(S_t) + \alpha \Big[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)\Big], \tag{11}$$

$$\text{Q-learning:} \quad Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t)\right]. \tag{12}$$

10.2. Estados/acciones continuos y aproximadores

Si $\mathcal{S}$ o $\mathcal{A}$ son continuos, se emplean aproximadores (p. ej., redes neuronales) para v, q o π, y algoritmos actor–critic o de control continuo (SAC, DDPG, PPO). El análisis requiere nociones de estabilidad y *funciones de Lyapunov* en ciertos casos; estos temas exceden el alcance de este capítulo introductorio.

11. Buenas prácticas y consideraciones empíricas

- **Estacionariedad:** el formalismo asume que P y r no cambian en el tiempo; ante no estacionariedad se usan ventanas móviles, γ más bajo o técnicas de *meta-RL*.
- **Exploración:** e-greedy, Boltzmann, ruido de acción, o políticas estocásticas explícitas.
- **Criterios de evaluación:** separación temporal (train/val/test), estabilidad ante perturbaciones, y métricas de riesgo si aplica (finanzas, robótica).

Agradecimientos

Este material fue elaborado para el Semillero de Aprendizaje por Refuerzo del Programa de Ciencia de Datos, Universidad Externado de Colombia, siguiendo la referencia clásica de Sutton y Barto.

Referencias

[1] Richard S. Sutton y Andrew G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018. Disponible en línea.