Modelo de Aprendizaje por Refuerzo para Trading en Mercado Spot

Capítulo 2 — MDP detallado, con ejemplos paso a paso

Prof. Julián Fernando Sánchez
Semillero de Aprendizaje por Refuerzo
Programa de Ciencia de Datos
Universidad Externado de Colombia

23 de septiembre de 2025

Índice

1. Objetivo y mapa del capítulo **2**

2. Datos, discretización y construcción del estado **2**
2.1. Variable de mercado M_t 2
2.2. Componente de posición I_t 3

3. Acciones, admisibilidad y dinámica de inventario **3**
3.1. Acciones 3

4. Cómo estimar las probabilidades de transición del mercado **4**
4.1. Frecuencias relativas (MLE) 4
4.2. Suavizado de Laplace (evitar ceros) 6

5. Recompensa: P&L neto con costos (retornos no constantes) **6**
5.1. Recompensa esperada paso a paso 9

6. Transiciones del MDP **13**
6.1. Forma escalar 13
6.2. Forma matricial por acción 13

7. Funciones de valor y ecuaciones de Bellman **15**
7.1. MDP del problema: estados, acciones y dinámica 15
7.2. Horizonte finito T: formulación y retroinducción 16

8. De los datos a la política (horizonte finito T) **22**

1. Objetivo y mapa del capítulo

Construir un modelo de Aprendizaje por Refuerzo (RL) para trading en el **mercado spot**, desde cero y de manera didáctica. Para cada concepto formal mostramos su *instanciación* en el trading y un *ejemplo numérico inmediato*. Al final, resolvemos un ejemplo completo.

- Diseño del MDP: $S_t = (M_t, I_t)$, acciones (Buy/Sell/Hold) y recompensas con costos.
- Derivación de las probabilidades de transición T desde datos (frecuencias, suavizado de Laplace, estimación bayesiana, ventanas móviles, y alternativa HMM).
- Bellman escalar y matricial, con interpretación financiera.
- Pseudocódigo especializado y chequeos de coherencia.
- Ejemplo *completo* con resolución (iteración de valores y evaluación de una política fija), paso a paso.

2. Datos, discretización y construcción del estado

2.1. Variable de mercado M_t

Sean precios spot $\{P_t\}_{t\geq 0}$ a intervalo fijo (p. ej., 5 min). Definimos el retorno logarítmico $r_t = \log(P_t/P_{t-1})$. Construimos el *régimen de mercado* binario

$$M_t = \begin{cases} U, & r_t > \theta, \\ D, & r_t \leq \theta, \end{cases}$$

con umbral θ (por defecto $\theta = 0$; se puede usar un pequeño sesgo para filtrar ruido).

Ejemplo 2.1 (Construir M_t desde datos)**.** Suponga 10 retornos:

$(0{,}004, -0{,}006, 0{,}001, 0{,}002, -0{,}003, 0{,}005, -0{,}004, -0{,}002, 0{,}006, 0{,}003)$. Con $\theta = 0$: M_t: U,D,U,U,D,U,D,D,U,U.

2.2. Componente de posición I_t

En mercado spot limitamos el inventario a $I_t \in \{0, 1\}$: 0 sin posición, 1 largo unitario. El estado total es $S_t = (M_t, I_t)$, por lo que $|\mathcal{S}| = 4$.

Ejemplo 2.2 (Estados observados (acciones admisibles))**.** Convención de índices: $t = 1, \ldots, 10$. El agente observa $M_t \in \{U, D\}$ y ejecuta $A_t \in \{\mathsf{Buy}, \mathsf{Sell}, \mathsf{Hold}\}$. La posición $I_t \in \{0, 1\}$ se actualiza *después* de A_t, con $I_0 = 0$ (plano). Regla (solo acciones admisibles):

$$I_t = \begin{cases} 1, & \text{si } A_t = \mathsf{Buy} \text{ y } I_{t-1} = 0, \\ 0, & \text{si } A_t = \mathsf{Sell} \text{ y } I_{t-1} = 1, \\ I_{t-1}, & \text{si } A_t = \mathsf{Hold}. \end{cases}$$

Dado $M_t = (U, D, U, U, D, U, D, D, U, U)$, tomamos acciones *admisibles*: Buy en $t = 1$, Sell en $t = 7$; las demás son Hold. Entonces:

Índice t	M_t	A_t	$I_{t-1} \to I_t$
1	U	Buy	$0 \to 1$
2	D	Hold	$1 \to 1$
3	U	Hold	$1 \to 1$
4	U	Hold	$1 \to 1$
5	D	Hold	$1 \to 1$
6	U	Hold	$1 \to 1$
7	D	Sell	$1 \to 0$
8	D	Hold	$0 \to 0$
9	U	Hold	$0 \to 0$
10	U	Hold	$0 \to 0$

Por tanto,

$$I_t = (1, 1, 1, 1, 1, 1, 0, 0, 0, 0),$$

y los estados visitados (M_t, I_t) pertenecen a $\{(U, 0), (D, 0), (U, 1), (D, 1)\}$.

3. Acciones, admisibilidad y dinámica de inventario

3.1. Acciones

Acciones $\mathcal{A} = \{\texttt{Buy}, \texttt{Sell}, \texttt{Hold}\}$. La *admisibilidad* depende de I_t:

I_t	Acciones admisibles	Actualización determinista de I_{t+1}
0	Buy, Hold	$I_{t+1} = 1$ si Buy; $I_{t+1} = 0$ si Hold
1	Sell, Hold	$I_{t+1} = 0$ si Sell; $I_{t+1} = 1$ si Hold

Comentario 3.1 (Causalidad). El inventario cambia solamente por la acción; el mercado M_t evoluciona *independientemente* de I_t.

4. Cómo estimar las probabilidades de transición del mercado

Definimos la matriz de transición de la cadena binaria (M_t):

$$T = \begin{pmatrix} \mathbb{P}(U \to U) & \mathbb{P}(U \to D) \\ \mathbb{P}(D \to U) & \mathbb{P}(D \to D) \end{pmatrix} = \begin{pmatrix} \alpha & 1-\alpha \\ 1-\beta & \beta \end{pmatrix}.$$

Ofrecemos varias rutas para estimar α, β a partir de datos.

4.1. Frecuencias relativas (MLE)

Consideremos una cadena de Markov de dos estados $M_t \in \{U, D\}$ (por ejemplo, Up y Down) con matriz de transición

$$T = \begin{pmatrix} \Pr(U \to U) & \Pr(U \to D) \\ \Pr(D \to U) & \Pr(D \to D) \end{pmatrix} = \begin{pmatrix} \alpha & 1-\alpha \\ 1-\beta & \beta \end{pmatrix}, \qquad \alpha, \beta \in (0,1).$$

Cómo contar. Dada una secuencia observada $M_1, \ldots, M_n$, las *transiciones* son los pares consecutivos (M_t, M_{t+1}) para $t = 1, \ldots, n-1$. Definimos los conteos:

$$N_{UU} = \#\{t : M_t = U, M_{t+1} = U\}, \quad N_{UD} = \#\{t : M_t = U, M_{t+1} = D\},$$

$$N_{DU} = \#\{t : M_t = D, M_{t+1} = U\}, \quad N_{DD} = \#\{t : M_t = D, M_{t+1} = D\}.$$

Los totales por fila (estado origen) son

$$N_{U\bullet} = N_{UU} + N_{UD} = \#\{t : M_t = U\}, \qquad N_{D\bullet} = N_{DU} + N_{DD} = \#\{t : M_t = D\},$$

y $N_{UU} + N_{UD} + N_{DU} + N_{DD} = n - 1$.

Verosimilitud y MLE. Asumiendo homogeneidad y primer orden, la verosimilitud se factoriza por filas:

$$\mathcal{L}(\alpha, \beta) = \alpha^{N_{UU}}(1-\alpha)^{N_{UD}} \cdot \beta^{N_{DD}}(1-\beta)^{N_{DU}}.$$

La log-verosimilitud es

$$\ell(\alpha, \beta) = N_{UU} \log \alpha + N_{UD} \log(1-\alpha) + N_{DD} \log \beta + N_{DU} \log(1-\beta).$$

Derivando e igualando a cero se obtienen los estimadores de máxima verosimilitud (MLE):

$$\hat{\alpha} = \frac{N_{UU}}{N_{U\bullet}}, \qquad \hat{\beta} = \frac{N_{DD}}{N_{D\bullet}},$$

es decir, *frecuencias relativas* por fila (proporción de permanencias desde cada estado).

Ejemplo 4.1 (Cálculo de MLE paso a paso)**.** Suponga que en 1,000 *transiciones* se observa:

$$N_{UU} = 350, \quad N_{UD} = 150, \quad N_{DU} = 200, \quad N_{DD} = 300,$$

de modo que $N_{U\bullet} = 500$, $N_{D\bullet} = 500$ y $N_{UU} + N_{UD} + N_{DU} + N_{DD} = 1000$ (consistencia).

1) Estimación por frecuencias relativas.

$$\hat{\alpha} = \frac{350}{350+150} = \frac{350}{500} = 0{,}70, \qquad \hat{\beta} = \frac{300}{200+300} = \frac{300}{500} = 0{,}60.$$

2) Matriz de transición estimada.

$$\hat{T} = \begin{pmatrix} 0{,}70 & 0{,}30 \\ 0{,}40 & 0{,}60 \end{pmatrix}, \quad \text{(cada fila suma 1).}$$

3) Incertidumbre (aprox. normal/Wald). Para una proporción binomial,

$$\mathrm{EE}(\hat{\alpha}) \approx \sqrt{\frac{\hat{\alpha}(1-\hat{\alpha})}{N_{U\bullet}}} = \sqrt{\frac{0{,}7 \cdot 0{,}3}{500}} \approx 0{,}0205,$$

$$\mathrm{EE}(\hat{\beta}) \approx \sqrt{\frac{\hat{\beta}(1-\hat{\beta})}{N_{D\bullet}}} = \sqrt{\frac{0{,}6 \cdot 0{,}4}{500}} \approx 0{,}0219.$$

Un IC del 95 % (Wald) es $\hat{\theta} \pm 1{,}96\,\mathrm{EE}$:

$$\hat{\alpha} \in [0{,}660,\ 0{,}740], \qquad \hat{\beta} \in [0{,}557,\ 0{,}643] \quad \text{(redondeado).}$$

4) Interpretación. $\hat{\alpha} = 0{,}70$ sugiere persistencia al alza: si hoy está en U, la probabilidad de que mañana siga en U es 70 %. $\hat{\beta} = 0{,}60$ indica persistencia moderada en D. En términos de rachas esperadas, $\mathbb{E}[\text{longitud de racha en } U] \approx 1/(1-\hat{\alpha}) \approx 3{,}33$ y en $D \approx 1/(1-\hat{\beta}) \approx 2{,}50$.

Buenas prácticas y casos límite.

- **Chequeos:** (i) $N_{UU} + N_{UD} + N_{DU} + N_{DD} = n - 1$; (ii) $N_{U\bullet}$ y $N_{D\bullet}$ coinciden con las veces que M_t estuvo en U o D (como estado *origen*); (iii) las filas de $\hat{T}$ suman 1.
- **Denominadores cero:** si $N_{U\bullet} = 0$ (nunca se observó U como origen), $\hat{\alpha}$ no está definido. Una regularización común es el suavizado de Laplace:

$$\tilde{\alpha} = \frac{N_{UU} + 1}{N_{U\bullet} + 2}, \qquad \tilde{\beta} = \frac{N_{DD} + 1}{N_{D\bullet} + 2}.$$

- **Claridad para estudiantes:** "1,000 transiciones" significa 1,000 pares (M_t, M_{t+1}); la secuencia de estados tiene entonces $n = 1001$ observaciones.

4.2. Suavizado de Laplace (evitar ceros)

Con conteos pequeños, evite probabilidades 0/1 extremas usando pseudoconteos $\kappa > 0$:

$$\tilde{\alpha} = \frac{N_{UU} + \kappa}{N_{UU} + N_{UD} + 2\kappa}, \qquad \tilde{\beta} = \frac{N_{DD} + \kappa}{N_{DU} + N_{DD} + 2\kappa}.$$

Ejemplo 4.2. Si $N_{UU} = 2, N_{UD} = 0$ y $\kappa = 1$, entonces $\tilde{\alpha} = (2+1)/(2+0+2) = 3/4 = 0{,}75$ en lugar de 1.

5. Recompensa: P&L neto con costos (retornos no constantes)

En este modelo trabajamos en tiempo discreto. Cada paso corresponde a un intervalo $[t, t{+}1)$, que *incluye* el instante inicial t pero *excluye* el final $t{+}1$. De esta forma, los intervalos no se solapan y cubren toda la línea temporal.

Retorno del intervalo. Definimos r_{t+1} como el *retorno realizado* en el tramo $[t, t{+}1)$. Aunque cubre ese intervalo, se indexa con $t+1$ porque su cálculo depende del precio de cierre P_{t+1} (ejemplo: $r_{t+1} = (P_{t+1} - P_t)/P_t$ o $r_{t+1} = \log P_{t+1} - \log P_t$). Por tanto, r_{t+1} sólo se conoce al llegar a $t+1$.

Posición. En el instante t el agente observa el estado (M_t, I_t) y decide una acción (Buy, Sell, Hold). Esta acción fija la posición *para todo el intervalo siguiente*:

$$I_{t+1} = \begin{cases} 1 & \text{si se ejecuta Buy,} \\ 0 & \text{si se ejecuta Sell,} \\ I_t & \text{si se ejecuta Hold.} \end{cases}$$

Obsérvese que, aunque I_{t+1} denota la posición durante $[t, t{+}1)$, es conocida ya desde t (pues se determina por la acción tomada en t). Es decir: I_{t+1} es *predecible* dado I_t y la acción.

Distribuciones condicionales del retorno. El retorno del tramo depende del régimen de mercado al cierre, $M_{t+1} \in \{U, D\}$. Formalmente:

$$r_{t+1} \mid (M_{t+1} = U) \sim F_U, \qquad \mathbb{E}[r_{t+1} \mid M_{t+1} = U] = \mu_U, \quad \mathrm{Var}(r_{t+1} \mid U) = \sigma_U^2,$$

$$r_{t+1} \mid (M_{t+1} = D) \sim F_D, \qquad \mathbb{E}[r_{t+1} \mid M_{t+1} = D] = \mu_D, \quad \mathrm{Var}(r_{t+1} \mid D) = \sigma_D^2.$$

Aquí F_U y F_D pueden ser distribuciones normales, t de Student, o incluso distribuciones empíricas calibradas con datos. Lo importante es que *las medias y varianzas difieren según el régimen*, capturando la asimetría de retornos en días alcistas o bajistas.

Recompensa del paso. El P&L incremental en el tramo $[t, t{+}1)$ es

$$R_{t+1} = I_{t+1}\, r_{t+1} - c\,|I_{t+1} - I_t|,$$

donde:

- $I_{t+1} r_{t+1}$ es la ganancia/pérdida del activo durante el intervalo, que sólo se obtiene si se está largo ($I_{t+1} = 1$).
- El término $c\,|I_{t+1} - I_t|$ es el costo de transacción incurrido si se cambió la posición (Buy o Sell); incluye comisión, *spread* y *slippage*.

Ejemplo ilustrativo (log-retorno). Supongamos $P_t = 100$ y $P_{t+1} = 101{,}2$. El retorno *logarítmico* es

$$r_{t+1} = \ln\!\left(\tfrac{101{,}2}{100}\right) \approx \ln(1{,}012) \approx 0{,}01193 = 1{,}193\,\%.$$

- **Caso 1 (Buy desde plano).** El agente estaba plano ($I_t = 0$) y ejecuta `Buy`, con lo cual $I_{t+1} = 1$. Entonces

$$R_{t+1} = 1 \cdot 0{,}01193 - c.$$

Con $c = 0{,}002$ (0.20 %), el P&L neto es $0{,}00993 \approx +\mathbf{0{,}993}\,\%$.

- **Caso 2 (Hold manteniendo largo).** El agente ya estaba largo ($I_t = 1$) y ejecuta `Hold`, por lo que $I_{t+1} = 1$ y no hay costo. En este caso

$$R_{t+1} = 1 \cdot 0{,}01193 = +\mathbf{1{,}193}\,\%.$$

- **Caso 3 (Sell cerrando largo).** El agente estaba largo ($I_t = 1$) y ejecuta `Sell`, de modo que $I_{t+1} = 0$. No participa del retorno y paga el costo:

$$R_{t+1} = 0 \cdot 0{,}01193 - 0{,}002 = -\mathbf{0{,}20}\,\%.$$

Resumen.

- r_{t+1} indexa el retorno *del próximo paso*, medido con P_{t+1}, aunque corresponda al intervalo $[t, t{+}1)$.
- I_{t+1} indexa la posición *durante el próximo tramo*, ya fijada en t por la acción.
- La distribución de r_{t+1} depende del régimen M_{t+1}: alcista (F_U) o bajista (F_D).
- La recompensa R_{t+1} combina el P&L por exposición más el costo de cambiar inventario.

Interpretación financiera. *Convención temporal:* la acción en t fija la posición I_{t+1} para el intervalo $[t, t+1)$; el retorno del paso es r_{t+1}. Con costo por cambio $c > 0$, el P&L es

$$R_{t+1} = I_{t+1}\, r_{t+1} - c\,|I_{t+1} - I_t|.$$

Casos relevantes:

- **Buy desde plano** ($I_t = 0 \to I_{t+1} = 1$): pagas costo y participas del retorno. $R_{t+1} = r_{t+1} - c$.
- **Sell cerrando largo** ($I_t = 1 \to I_{t+1} = 0$): pagas costo y no participas del retorno en este paso. $R_{t+1} = -c$.
- **Hold manteniendo largo** ($I_t = 1 \to I_{t+1} = 1$): no hay costo, participas del retorno. $R_{t+1} = r_{t+1}$.
- **Hold manteniéndose plano** ($I_t = 0 \to I_{t+1} = 0$): no hay costo ni participación. $R_{t+1} = 0$.

5.1. Recompensa esperada paso a paso

Hasta ahora hemos definido la *recompensa realizada* en el paso como

$$R_{t+1} = I_{t+1}\, r_{t+1} - c\,|I_{t+1} - I_t|,$$

donde $I_t \in \{0, 1\}$ es la posición al inicio de t, r_{t+1} es el retorno durante $[t, t+1)$ y $c > 0$ es el costo por cambiar inventario.

Nuestro objetivo es calcular la **recompensa esperada**

$$r((m, i), a) = \mathbb{E}[R_{t+1} \mid M_t = m,\ I_t = i,\ \text{acción } a],$$

es decir, el valor promedio de R_{t+1} condicionando en:

- El régimen actual del mercado $m \in \{U, D\}$.
- La posición actual $i \in \{0, 1\}$ (plano o largo).
- La acción elegida $a \in \{\texttt{Buy}, \texttt{Sell}, \texttt{Hold}\}$.

Paso 1. Nueva posición tras la acción. La acción determina la posición futura mediante una función $f(i, a)$:

$$f(i, a) = \begin{cases} 1 & \text{si } a = \texttt{Buy}, \\ 0 & \text{si } a = \texttt{Sell}, \\ i & \text{si } a = \texttt{Hold}. \end{cases}$$

Así, $I_{t+1} = f(i, a)$ y el costo de transacción será $c\,|f(i, a) - i|$.

Paso 2. Dependencia del régimen futuro. El retorno r_{t+1} depende del régimen del mercado en $t + 1$, denotado M_{t+1}:

$$\mathbb{E}[r_{t+1} \mid M_{t+1} = U] = \mu_U, \qquad \mathbb{E}[r_{t+1} \mid M_{t+1} = D] = \mu_D.$$

Paso 3. Probabilidades de transición de regímenes. Desde el régimen actual m, la probabilidad de pasar al siguiente $m' \in \{U, D\}$ está dada por la matriz de transición

$$T(m, m') = \Pr(M_{t+1} = m' \mid M_t = m).$$

Paso 4. Esperanza total. En este paso queremos calcular la *recompensa esperada* al tomar una acción a en el estado actual (m, i) en el tiempo t. Recordemos que la recompensa de un paso es

$$R_{t+1} = f(i, a)\, r_{t+1} - c\,|f(i, a) - i|,$$

donde $f(i, a)$ fija la posición durante el tramo $[t, t + 1)$, el término r_{t+1} es el retorno realizado en ese tramo, y $c\,|f(i, a) - i|$ es el costo fijo si hubo cambio de inventario.

Idea clave. En el instante t todavía no sabemos cuál será el régimen al final del tramo (M_{t+1}), pero sí conocemos su distribución condicional dado el régimen actual $M_t = m$. Por tanto, el retorno r_{t+1} es una variable aleatoria cuya media depende del evento $\{M_{t+1} = m'\}$, y la recompensa esperada debe construirse ponderando sobre los posibles escenarios futuros $m' \in \{U, D\}$.

Ley de la esperanza total. Si una variable aleatoria X depende de qué suceso A_k ocurra, y esos sucesos forman una partición, entonces

$$\mathbb{E}[X] = \sum_k \Pr(A_k)\, \mathbb{E}[X \mid A_k].$$

En nuestro caso:

- La variable aleatoria es el P&L R_{t+1}.
- Los sucesos que forman la partición son $A_U = \{M_{t+1} = U\}$ y $A_D = \{M_{t+1} = D\}$.
- Las probabilidades asociadas son $\Pr(M_{t+1} = m' \mid M_t = m) = T(m, m')$, que dependen del régimen actual m.

Aplicación concreta. Condicionando en el estado (m, i) y acción a, se tiene

$$r((m, i), a) = \mathbb{E}[R_{t+1} \mid M_t = m, I_t = i, a].$$

Usando la ley de la esperanza total sobre los escenarios $M_{t+1} = m'$:

$$r((m, i), a) = \sum_{m' \in \{U,D\}} \Pr(M_{t+1} = m' \mid M_t = m)\, \mathbb{E}[R_{t+1} \mid M_{t+1} = m', M_t = m, I_t = i, a]. \quad (1)$$

Descomposición dentro de cada escenario. El término de costo $-c\,|f(i, a) - i|$ es determinista dado (i, a) y no depende de m'. La única parte aleatoria es r_{t+1}, cuya esperanza

bajo cada régimen es

$$\mathbb{E}[r_{t+1} \mid M_{t+1} = U] = \mu_U, \qquad \mathbb{E}[r_{t+1} \mid M_{t+1} = D] = \mu_D.$$

Así, en cada escenario m':

$$\mathbb{E}[R_{t+1} \mid M_{t+1} = m', M_t = m, i, a] = f(i,a)\,\mu_{m'} - c\,|f(i,a) - i|.$$

Sustituyendo en la fórmula de esperanza total:

$$r((m,i),a) = \sum_{m' \in \{U,D\}} T(m,m') \Big(f(i,a)\,\mu_{m'} - c\,|f(i,a) - i| \Big). \tag{2}$$

Interpretación. La recompensa esperada en (m,i) al tomar a es un *promedio ponderado* de las recompensas esperadas en cada escenario futuro m', ponderado por las probabilidades de transición $T(m,m')$. El costo por cambiar inventario aparece en todos los escenarios porque se paga al inicio del tramo, independientemente de cuál régimen ocurra al final.

Paso 5. Simplificación. Como el costo no depende de m', la suma afecta solo al primer término:

$$r((m,i),a) = f(i,a) \Big(T(m,U)\mu_U + T(m,D)\mu_D \Big) - c\,|f(i,a) - i|. \tag{3}$$

Definimos la **media condicional del retorno** desde el régimen m como

$$\bar{\mu}(m) = T(m,U)\mu_U + T(m,D)\mu_D,$$

y la expresión queda más compacta:

$$\boxed{r((m,i),a) = f(i,a)\,\bar{\mu}(m) - c\,|f(i,a) - i|.}$$

Paso 6. Caso binario estándar. Con dos parámetros de persistencia α, β la matriz es

$$T(U,U) = \alpha, \quad T(U,D) = 1 - \alpha, \quad T(D,U) = 1 - \beta, \quad T(D,D) = \beta.$$

Entonces

$$\bar{\mu}(U) = \alpha\,\mu_U + (1-\alpha)\,\mu_D, \qquad \bar{\mu}(D) = (1-\beta)\,\mu_U + \beta\,\mu_D.$$

Ejemplo 5.1 (Cómputo de $r(s,a)$ con unidades decimales)**.** Suponga $\alpha = 0{,}7$, $\beta = 0{,}6$, $\mu_U = 0{,}006$, $\mu_D = -0{,}010$ y costo $c = 0{,}002$. Entonces

$$\bar{\mu}(U) = 0{,}7\cdot 0{,}006 + 0{,}3\cdot(-0{,}010) = 0{,}0012, \qquad \bar{\mu}(D) = 0{,}4\cdot 0{,}006 + 0{,}6\cdot(-0{,}010) = -0{,}0036.$$

Recompensas esperadas:

$$\begin{aligned}
r((U,0),\texttt{Buy}) &= 1\cdot 0{,}0012 - 0{,}002 = -0{,}0008, & r((U,0),\texttt{Hold}) &= 0\cdot 0{,}0012 - 0 = 0{,}0000,\\
r((U,1),\texttt{Hold}) &= 1\cdot 0{,}0012 - 0 = 0{,}0012, & r((U,1),\texttt{Sell}) &= 0\cdot 0{,}0012 - 0{,}002 = -0{,}0020,\\
r((D,0),\texttt{Buy}) &= 1\cdot(-0{,}0036) - 0{,}002 = -0{,}0056, & r((D,1),\texttt{Hold}) &= 1\cdot(-0{,}0036) - 0 = -0{,}0036,\\
r((D,1),\texttt{Sell}) &= 0\cdot(-0{,}0036) - 0{,}002 = -0{,}0020.
\end{aligned}$$

(Opcional) Dispersión de la recompensa. La varianza condicional también se puede calcular de forma cerrada:

$$\mathrm{Var}(R_{t+1} \mid m,i,a) = f(i,a)^2\Big(T(m,U)\sigma_U^2 + T(m,D)\sigma_D^2 + T(m,U)T(m,D)(\mu_U - \mu_D)^2\Big),$$

lo cual resulta útil para estudiar criterios de riesgo–retorno.

(Cierre) Matrices de recompensas por acción. Sea el orden de estados $[(U,0),(U,1),(D,0),(D,1)]$. Recordando $r((m,i),a) = f(i,a)\,\bar{\mu}(m) - c\,|f(i,a) - i|$, con

$$\bar{\mu}(U) = \alpha\,\mu_U + (1-\alpha)\,\mu_D, \qquad \bar{\mu}(D) = (1-\beta)\,\mu_U + \beta\,\mu_D,$$

podemos apilar las *recompensas esperadas* en vectores por acción:

$$\mathbf{r}_{\texttt{Buy}} = \begin{bmatrix} \bar{\mu}(U) - c \\ \text{n/a} \\ \bar{\mu}(D) - c \\ \text{n/a} \end{bmatrix}, \qquad \mathbf{r}_{\texttt{Sell}} = \begin{bmatrix} \text{n/a} \\ -c \\ \text{n/a} \\ -c \end{bmatrix}, \qquad \mathbf{r}_{\texttt{Hold}} = \begin{bmatrix} 0 \\ \bar{\mu}(U) \\ 0 \\ \bar{\mu}(D) \end{bmatrix}.$$

Para visualizarlas juntas, construimos la *matriz de recompensas* estado–acción

$$\mathcal{R} \;=\; \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{ccc} \texttt{Buy} & \texttt{Sell} & \texttt{Hold} \end{array} \\ \begin{pmatrix} \bar{\mu}(U) - c & \text{n/a} & 0 \\ \text{n/a} & -c & \bar{\mu}(U) \\ \bar{\mu}(D) - c & \text{n/a} & 0 \\ \text{n/a} & -c & \bar{\mu}(D) \end{pmatrix} \end{array}.$$

Uso computacional. Para resolver Bellman de *optimalidad* con un máximo componente a componente, es habitual enmascarar acciones inadmisibles asignándoles $-\infty$ (o un número muy negativo) en lugar de "n/a". Defina entonces

$$\tilde{\mathcal{R}}(s,a) = \begin{cases} r(s,a), & \text{si } a \text{ es admisible en } s, \\ -\infty, & \text{si } a \text{ es inadmisible en } s, \end{cases}$$

y utilice $\tilde{\mathcal{R}}$ en $\mathbf{v}^* = \text{máx}_a\{\ \mathbf{r}_a + \gamma P_a\, \mathbf{v}^*\ \}$.

6. Transiciones del MDP

6.1. Forma escalar

Para $s = (m, i)$ y acción a:

$$P\Big((m', i') \mid (m, i), a\Big) = T(m, m')\, \mathbb{1}\{i' = f(i, a)\}.$$

6.2. Forma matricial por acción

Para representar el problema como un proceso de decisión de Markov (MDP), numeramos los estados de la forma siguiente:

$$1 : (U, 0), \qquad 2 : (U, 1), \qquad 3 : (D, 0), \qquad 4 : (D, 1).$$

Cada matriz P_a describe las probabilidades de transición de estados cuando se elige la acción $a \in \{\texttt{Buy}, \texttt{Sell}, \texttt{Hold}\}$. Las filas corresponden al estado de origen (1–4) y las columnas al estado de destino (1–4). Si una fila resulta nula, significa que la acción a es *inadmisible* en ese estado (por ejemplo, intentar `Buy` cuando ya se está largo).

Acción Buy. Al comprar desde una posición plana ($i = 0$), se pasa a la misma fila de régimen pero con $i = 1$. Si ya se está largo ($i = 1$), la acción no es admisible (filas nulas).

$$P_{\texttt{Buy}} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} 0 & \alpha & 0 & 1-\alpha \\ 0 & 0 & 0 & 0 \\ 0 & 1-\beta & 0 & \beta \\ 0 & 0 & 0 & 0 \end{pmatrix} \end{array}.$$

Acción Sell. Al vender desde una posición larga ($i = 1$), se pasa al mismo régimen futuro pero con $i = 0$. Si se está plano ($i = 0$), la acción es inadmisible (filas nulas).

$$P_{\texttt{Sell}} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} 0 & 0 & 0 & 0 \\ \alpha & 0 & 1-\alpha & 0 \\ 0 & 0 & 0 & 0 \\ 1-\beta & 0 & \beta & 0 \end{pmatrix} \end{array}.$$

Acción Hold. Al mantener, el agente conserva su inventario. Si está plano permanece en $i = 0$, y si está largo permanece en $i = 1$. Todas las filas son válidas.

$$P_{\texttt{Hold}} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} \alpha & 0 & 1-\alpha & 0 \\ 0 & \alpha & 0 & 1-\alpha \\ 1-\beta & 0 & \beta & 0 \\ 0 & 1-\beta & 0 & \beta \end{pmatrix} \end{array}.$$

Interpretación. Las filas corresponden al estado de origen y las columnas al estado de destino. Cada entrada da la probabilidad de pasar del estado fila al estado columna al elegir la acción indicada. Por ejemplo, en $P_{\texttt{Buy}}$, la entrada en la fila $(U, 0)$ y columna $(U, 1)$ es α, lo que significa: si hoy estás en régimen U sin posición y decides comprar, mañana permanecerás en U y estarás largo con probabilidad α.

Observación. El bloque superior (filas 1 y 2) corresponde a estar actualmente en régimen U, mientras que el bloque inferior (filas 3 y 4) corresponde a estar en régimen D. En cada caso, la probabilidad de transición al siguiente régimen está gobernada por α (persistencia en U) y β (persistencia en D).

7. Funciones de valor y ecuaciones de Bellman

7.1. MDP del problema: estados, acciones y dinámica

Espacio de estados. Trabajamos con cuatro estados $s = (m, i)$ que combinan *régimen* $m \in \{U, D\}$ e *inventario* $i \in \{0, 1\}$:

$$\mathcal{S} = \{(U,0),(U,1),(D,0),(D,1)\} \quad \Longleftrightarrow \quad \begin{array}{l} 1:(U,0), \\ 2:(U,1), \\ 3:(D,0), \\ 4:(D,1). \end{array}$$

Acciones admisibles por estado.

$$\mathcal{A}(U,0) = \{\texttt{Buy}, \texttt{Hold}\}, \quad \mathcal{A}(U,1) = \{\texttt{Sell}, \texttt{Hold}\}, \quad \mathcal{A}(D,0) = \{\texttt{Buy}, \texttt{Hold}\}, \quad \mathcal{A}(D,1) = \{\texttt{Sell}, \texttt{Hold}\}.$$

(Comprar ya estando largo o vender ya estando plano son *inadmisibles*.)

Transiciones del régimen e inventario. El régimen sigue una cadena de dos estados con

$$T(U,U) = \alpha, \quad T(U,D) = 1-\alpha, \qquad T(D,U) = 1-\beta, \quad T(D,D) = \beta,$$

mientras que el inventario para el siguiente paso se fija con

$$f(i, \texttt{Buy}) = 1, \quad f(i, \texttt{Sell}) = 0, \quad f(i, \texttt{Hold}) = i.$$

Esto induce, para cada acción a, una matriz $P_a \in \mathbb{R}^{4\times 4}$ de probabilidades $P(s' \mid s, a)$ (ver sección de "forma matricial por acción").

Recompensa inmediata esperada. La recompensa (P&L) del paso $[t, t{+}1)$ es $R_{t+1} = I_{t+1}\, r_{t+1} - c\,|I_{t+1} - I_t|$. Su esperanza condicional es

$$r(s,a) = f(i,a)\,\bar{\mu}(m) - c\,|f(i,a) - i|, \quad \text{donde} \quad \bar{\mu}(m) = T(m,U)\mu_U + T(m,D)\mu_D.$$

Para acciones inadmisibles, *no* definimos $r(s,a)$ (equivalentemente, puede considerarse $-\infty$ para enmascarar en máximos).

7.2. Horizonte finito T: formulación y retroinducción

Línea de tiempo y episodios. El proceso de decisión se desarrolla a lo largo de un horizonte discreto de longitud finita $T \in \mathbb{N}$, con tiempos $t = 0, 1, \ldots, T$. En cada paso $t < T$, el agente observa el estado S_t, elige una acción A_t dentro del conjunto de acciones admisibles $\mathcal{A}(S_t)$, recibe una recompensa R_{t+1} correspondiente al intervalo $[t, t+1)$, y el sistema transita al nuevo estado S_{t+1}.

Condición terminal. Al final del episodio ($t = T$), puede definirse un *pago terminal* $G(S_T)$, que representa una recompensa adicional o penalización por la condición final del sistema. En problemas sin recompensa terminal, se asume $G \equiv 0$.

Políticas dependientes del tiempo. Una política π con horizonte finito es una secuencia $\pi = \{\pi_t\}_{t=0}^{T-1}$ donde cada π_t es una familia de distribuciones de probabilidad sobre $\mathcal{A}(s)$:

$$\pi_t(a \mid s) \geq 0, \qquad \sum_{a \in \mathcal{A}(s)} \pi_t(a \mid s) = 1.$$

La política puede ser estocástica (mezcla probabilística entre acciones) o determinista (una sola acción elegida con probabilidad 1 en cada estado).

Función de valor de una política. Dada una política π, el valor de estado en el tiempo t es el valor esperado de las recompensas futuras hasta el final del episodio, condicionado a iniciar en $S_t = s$:

$$v_t^\pi(s) = \mathbb{E}_\pi \left[\sum_{k=t}^{T-1} R_{k+1} + G(S_T) \;\middle|\; S_t = s \right].$$

Función valor acción–estado. El valor acción–estado $q_t^\pi(s, a)$ representa la recompensa esperada al tomar la acción a en el estado s en el tiempo t, y luego seguir la política π:

$$q_t^\pi(s, a) = \mathbb{E}_\pi \left[R_{t+1} + \sum_{k=t+1}^{T-1} R_{k+1} + G(S_T) \;\middle|\; S_t = s,\ A_t = a \right].$$

Recursión de Bellman. La función de valor se construye de forma recursiva hacia atrás en el tiempo, desde el instante final $t = T$ hasta el instante inicial $t = 0$. Este procedimiento recibe el nombre de *retroinducción* (o *backward induction*), y se basa en descomponer el valor total esperado en dos componentes fundamentales:

- La **recompensa inmediata esperada** al tomar una acción en el estado actual.

- El **valor esperado futuro**, que proviene de la evolución del sistema bajo la política desde el siguiente estado.

Para cada etapa $t \in \{0, 1, \ldots, T-1\}$ y estado $s \in \mathcal{S}$, la **función de valor bajo una política** π se define recursivamente como:

$$v_T^\pi(s) = G(s),$$

$$v_t^\pi(s) = \sum_{a \in \mathcal{A}(s)} \pi_t(a \mid s) \left[r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s, a)\, v_{t+1}^\pi(s') \right].$$

Esta ecuación expresa que el valor de estar en s en el tiempo t consiste en:

1. Promediar, según la política π_t, sobre todas las acciones admisibles a en s;
2. Para cada acción a, calcular la suma de:
   - la recompensa inmediata esperada $r(s,a)$;
   - el valor esperado del siguiente estado s', ponderado por la probabilidad de transitar a s' al ejecutar a en s.

Alternativamente, se define la **función acción–valor** (también llamada función Q), que representa el valor esperado de tomar una acción específica a en s en el tiempo t, y seguir la política π desde $t+1$ en adelante:

$$q_t^\pi(s,a) = r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s, a)\, v_{t+1}^\pi(s').$$

Una vez calculados los valores $q_t^\pi(s,a)$ para todas las acciones admisibles, se puede reconstruir $v_t^\pi(s)$ como un promedio ponderado:

$$v_t^\pi(s) = \sum_{a \in \mathcal{A}(s)} \pi_t(a \mid s)\, q_t^\pi(s,a).$$

Interpretación pedagógica. Esta recursión formaliza la idea de que la utilidad de estar en un estado hoy depende de:

- qué acciones son elegidas hoy,
- qué recompensas se obtienen de inmediato,
- y cómo esas decisiones afectan la posición futura, medida a través de v_{t+1}^π.

La estructura recursiva permite computar los valores de forma descendente desde el final hacia el inicio, partiendo de una condición terminal $v_T^\pi(s) = G(s)$ que actúa como ancla para los cálculos.

Caso sin política (óptimo). Cuando se busca la política óptima, se reemplaza el promedio ponderado por un operador *máximo*:

$$v_t^*(s) = \max_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s,a)\, v_{t+1}^*(s') \right],$$

$$q_t^*(s,a) = r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s,a)\, v_{t+1}^*(s').$$

Esto permite definir una política codiciosa por etapa:

$$\pi_t^*(s) \in \arg\max_{a \in \mathcal{A}(s)} q_t^*(s,a).$$

Lectura de las ecuaciones. Cada una de estas expresiones tiene una lectura intuitiva:

- *Valor de política* $v_t^\pi(s)$: expectativa total de recompensas futuras desde el estado s siguiendo la política π.
- *Valor acción–estado* $q_t^\pi(s,a)$: cuánto vale tomar a en s en t, anticipando los futuros movimientos del sistema.
- *Ecuación óptima* $v_t^*(s)$: mejor valor alcanzable desde s en t, considerando la mejor acción posible.

Estas funciones permiten comparar distintas políticas, construir políticas óptimas, y analizar el impacto de decisiones locales sobre el rendimiento acumulado.

Valor óptimo y política óptima. El valor óptimo en cada etapa es el máximo valor posible que puede obtenerse desde un estado dado si se siguen decisiones óptimas desde ese momento hasta el final:

$$v_t^*(s) = \max_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s,a)\, v_{t+1}^*(s') \right], \quad v_T^*(s) = G(s).$$

La política óptima en cada etapa se define como:

$$\pi_t^*(s) \in \arg\max_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s,a)\, v_{t+1}^*(s') \right].$$

Interpretación. Esta formulación permite modelar decisiones secuenciales donde el agente conoce el número de pasos restantes. En cada instante t, la acción óptima puede cambiar porque el "valor del futuro"se reduce al acercarse a T. Esto refleja que ciertas estrategias pueden ser óptimas en el largo plazo pero no cuando queda poco tiempo para ejecutar decisiones.

Ejemplo con $T = 3$. Sea $T = 3$ y $G \equiv 0$, con recompensas y transiciones estacionarias. El cálculo de valores se hace de manera descendente:

$$
\begin{aligned}
v_3^*(s) &= 0, \\
v_2^*(s) &= \operatorname*{máx}_{a \in \mathcal{A}(s)} r(s,a), \\
v_1^*(s) &= \operatorname*{máx}_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s'} P(s' \mid s,a)\, v_2^*(s') \right], \\
v_0^*(s) &= \operatorname*{máx}_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s'} P(s' \mid s,a)\, v_1^*(s') \right].
\end{aligned}
$$

Forma matricial (compacta y computable). En problemas con espacio de estados finito, es posible representar las funciones y operadores del MDP en forma matricial, lo que permite realizar los cálculos de manera más eficiente, compacta y clara. A continuación se describe esta formulación, partiendo de la forma escalar y pasando a su versión matricial.

Versión escalar (por estado y acción). La ecuación de Bellman para una política dada $\pi = \{\pi_t\}_{t=0}^{T-1}$ y una etapa $t < T$ se expresa, en forma escalar, como:

$$
v_t^\pi(s) = \sum_{a \in \mathcal{A}(s)} \pi_t(a \mid s) \left[r(s,a) + \sum_{s' \in \mathcal{S}} P(s' \mid s,a)\, v_{t+1}^\pi(s') \right].
$$

Esta expresión:

- Promedia sobre las acciones a, usando la política $\pi_t(a \mid s)$,
- Suma la recompensa inmediata esperada $r(s,a)$,
- Y agrega el valor esperado futuro, ponderado por las transiciones a estados siguientes s'.

Aunque esta forma es útil para razonamiento teórico y para problemas pequeños, resulta menos conveniente computacionalmente, especialmente cuando el número de estados y acciones crece.

Versión matricial. Para convertir esta formulación a una forma matricial más compacta, se realiza lo siguiente:

1. **Enumeración de los estados.** Fijamos un orden en los estados:

$$s_1 = (U, 0), \quad s_2 = (U, 1), \quad s_3 = (D, 0), \quad s_4 = (D, 1).$$

   Por tanto, toda función definida sobre $\mathcal{S}$ puede representarse como un vector columna en $\mathbb{R}^4$.

2. **Vector de recompensas por acción.** Para cada acción a, se define el vector de recompensas inmediatas esperadas como:

$$\mathbf{r}_a = \begin{bmatrix} r(s_1, a) \\ r(s_2, a) \\ r(s_3, a) \\ r(s_4, a) \end{bmatrix} \in \mathbb{R}^4.$$

3. **Matriz de transición por acción.** Para cada acción a, se define la matriz de transición:

$$P_a = [\, P(s_j \mid s_i, a) \,]_{i,j=1}^{4} \in \mathbb{R}^{4\times 4},$$

   donde la fila i representa la distribución de probabilidad sobre estados siguientes s_j al ejecutar la acción a en el estado s_i.

4. **Política como matriz diagonal.** En la formulación matricial, la política en una etapa t se representa mediante una colección de matrices diagonales, una por cada acción a. Cada matriz indica, en su diagonal, la probabilidad de ejecutar la acción a en cada estado s_i. Formalmente:

$$\Pi_{a,t} = \operatorname{diag}\left(\pi_t(a \mid s_1),\, \pi_t(a \mid s_2),\, \pi_t(a \mid s_3),\, \pi_t(a \mid s_4)\right) \in \mathbb{R}^{4\times 4}.$$

   Ejemplo. Supongamos que en la etapa $t = 1$ la política asigna las siguientes probabilidades:

	`Buy`	`Sell`	`Hold`
$s_1 = (U, 0)$	0,7	0	0,3
$s_2 = (U, 1)$	0	0,8	0,2
$s_3 = (D, 0)$	0,4	0	0,6
$s_4 = (D, 1)$	0	0,9	0,1

A partir de esta tabla, las matrices diagonales asociadas son:

$$\Pi_{\texttt{Buy},1} = \begin{bmatrix} 0{,}7 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0{,}4 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad \Pi_{\texttt{Sell},1} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0{,}8 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0{,}9 \end{bmatrix},$$

$$\Pi_{\texttt{Hold},1} = \begin{bmatrix} 0{,}3 & 0 & 0 & 0 \\ 0 & 0{,}2 & 0 & 0 \\ 0 & 0 & 0{,}6 & 0 \\ 0 & 0 & 0 & 0{,}1 \end{bmatrix}.$$

Cada una de estas matrices coloca en su diagonal las probabilidades de tomar la acción correspondiente en cada estado. La suma de las matrices $\Pi_{a,t}$ sobre todas las acciones a da la identidad, reflejando que en cada estado debe elegirse alguna acción con probabilidad total 1.

5. **Promedio de recompensas y transiciones.** A partir de estas matrices, se construyen los promedios ponderados de recompensas y transiciones en la etapa t:

$$\mathbf{r}_{\pi_t} = \sum_a \Pi_{a,t}\, \mathbf{r}_a, \qquad P_{\pi_t} = \sum_a \Pi_{a,t}\, P_a.$$

6. **Recursión de Bellman en forma matricial.** Definiendo el vector de valores $\mathbf{v}_t = [v_t(s_1),\, v_t(s_2),\, v_t(s_3),\, v_t(s_4)]^\top$, se tiene:

$$\mathbf{v}_T = \mathbf{g}, \qquad \mathbf{v}_t = \mathbf{r}_{\pi_t} + P_{\pi_t}\mathbf{v}_{t+1}.$$

Donde $\mathbf{g}$ es el vector de pagos terminales: $\mathbf{g} = [G(s_1),\, G(s_2),\, G(s_3),\, G(s_4)]^\top$.

Caso óptimo (forma matricial de Bellman óptima). Cuando se busca el valor óptimo en lugar del valor bajo una política dada, no se promedia con π_t sino que se maximiza directamente sobre las acciones admisibles. La versión escalar óptima es:

$$v_t^*(s) = \operatorname*{máx}_{a \in \mathcal{A}(s)} \left[r(s,a) + \sum_{s'} P(s' \mid s,a)\, v_{t+1}^*(s') \right].$$

Esta expresión se puede llevar a forma matricial componente a componente. Dado que cada acción a define su propio vector de recompensas $\mathbf{r}_a$ y matriz de transición P_a, se calcula:

$$\mathbf{v}_t^* = \max_{a \in \mathcal{A}} \left\{ \mathbf{r}_a + P_a \, \mathbf{v}_{t+1}^* \right\}.$$

Aquí, el operador **máximo** se interpreta *componente a componente*: para cada estado s_i, se considera el valor resultante de aplicar cada acción admisible $a \in \mathcal{A}(s_i)$, y se elige la acción que produce el mayor valor total inmediato más futuro.

Máscara de admisibilidad. Dado que no todas las acciones son válidas en todos los estados, es necesario respetar las restricciones del conjunto $\mathcal{A}(s)$. Esto se puede manejar de dos formas:

1. **Filtrado dinámico:** al calcular máx en cada estado, se evalúan solo las acciones $a \in \mathcal{A}(s_i)$.
2. **Enmascaramiento:** se asigna un valor prohibitivo (por ejemplo, $-\infty$) a la recompensa $r(s, a)$ cuando $a \notin \mathcal{A}(s)$, de modo que esa acción nunca sea seleccionada por el operador máx.

Observaciones finales. La formulación matricial tiene ventajas importantes:

- Permite programar y resolver el problema de manera más eficiente, especialmente cuando se usan librerías vectorizadas o aceleradas por GPU.
- Refleja claramente la estructura lineal (en el caso de una política fija) o pieza por pieza (en el caso óptimo).
- Facilita el uso de álgebra lineal y métodos iterativos como la iteración de valores.
- Hace más natural la extensión a casos con mayor número de estados o múltiples activos.

Este enfoque, aplicado a problemas con horizonte finito, permite simular, optimizar y analizar políticas de trading con estructura temporal clara, interpretando el valor de cada decisión en función del tiempo restante, el régimen del mercado y el inventario del agente.

8. De los datos a la política (horizonte finito T)

En esta sección se establece el recorrido completo desde las *series de precios* hasta la *política óptima no estacionaria* $\{\pi_t^*\}_{t=0}^{T-1}$ en un horizonte discreto y finito $t = 0, 1, \ldots, T$. Partimos de datos de mercado, construimos retornos y regímenes (M_t), estimamos transiciones

y recompensas esperadas, formulamos el MDP por etapa (matrices $P_{a,t}$ y vectores $\mathbf{r}_{a,t}$), y resolvemos por *retroinducción* (backward induction) las ecuaciones de Bellman finito–horizonte. El resultado es una regla de decisión óptima dependiente del tiempo restante $T-t$.

Algorithm 1 Acciones admisibles y actualización de inventario $f(i,a)$

Entradas: inventario $i \in \{0,1\}$; acción $a \in \{\texttt{Buy}, \texttt{Sell}, \texttt{Hold}\}$
Salidas: conjunto de acciones admisibles $\mathcal{A}(i)$; inventario siguiente $i^+ = f(i,a)$
Acciones admisibles:
if $i = 0$ **then**
  $\mathcal{A}(i) \leftarrow \{\texttt{Buy}, \texttt{Hold}\}$
else
  $\mathcal{A}(i) \leftarrow \{\texttt{Sell}, \texttt{Hold}\}$
end if
Actualización determinista:

$$f(i,a) = \begin{cases} 1, & a = \texttt{Buy}, \\ 0, & a = \texttt{Sell}, \\ i, & a = \texttt{Hold}. \end{cases}$$

=0

Algorithm 2 Construir retornos log y régimen binario M_t

Entrada: precios $\{P_t\}_{t=0}^{n}$; umbral θ (por defecto $\theta = 0$)
Salida: retornos $r_t = \log(P_t/P_{t-1})$ para $t = 1{:}n$; régimen $M_t \in \{U, D\}$ para $t = 1{:}n$
for $t = 1$ **to** n **do**
  $r_t \leftarrow \log(P_t) - \log(P_{t-1})$
  $M_t \leftarrow \begin{cases} U, & r_t > \theta \\ D, & r_t \leq \theta \end{cases}$
end for
Chequeos: proporciones de U/D razonables; sensibilidad a θ. =0

Algorithm 3 Conteo de transiciones y MLE de (α, β)

Entrada: $M_1, \ldots, M_n$ con $M_t \in \{U, D\}$
Salida: $\widehat{\alpha}, \widehat{\beta}$; $\widehat{T}$
Inicializar $N_{UU}, N_{UD}, N_{DU}, N_{DD} \leftarrow 0$
for $t = 1$ **to** $n - 1$ **do**
  Incrementar el conteo correspondiente a (M_t, M_{t+1})
end for
$N_{U\bullet} \leftarrow N_{UU} + N_{UD}; \quad N_{D\bullet} \leftarrow N_{DU} + N_{DD}$
MLE: $\widehat{\alpha} \leftarrow \dfrac{N_{UU}}{N_{U\bullet}}; \;\; \widehat{\beta} \leftarrow \dfrac{N_{DD}}{N_{D\bullet}}$
(Opcional) Laplace con $\kappa > 0$: $\quad \tilde{\alpha} \leftarrow \dfrac{N_{UU} + \kappa}{N_{U\bullet} + 2\kappa}, \;\; \tilde{\beta} \leftarrow \dfrac{N_{DD} + \kappa}{N_{D\bullet} + 2\kappa}$
Construir $\widehat{T} = \begin{pmatrix} \widehat{\alpha} & 1 - \widehat{\alpha} \\ 1 - \widehat{\beta} & \widehat{\beta} \end{pmatrix}$
Chequeos: filas de $\widehat{T}$ suman 1; N_{**} consistentes. =0

Nota (estacionario vs. dependiente de t). En horizonte finito pueden usarse transiciones *estacionarias* ($T_t \equiv T$) para simplificar, o *dependientes del tiempo* (T_t) si se desea capturar estacionalidad. En lo que sigue, se muestran ambas posibilidades con subíndices t cuando aplica.

Algorithm 4 Estimación de medias por régimen futuro: $\mu_U = \mathbb{E}[r_{t+1} \mid M_{t+1} = U]$, $\mu_D = \mathbb{E}[r_{t+1} \mid M_{t+1} = D]$

Entrada: retornos r_{t+1} para $t = 0{:}n - 1$; etiquetas $M_{t+1} \in \{U, D\}$
Salida: $\widehat{\mu}_U$, $\widehat{\mu}_D$ (y opcional $\widehat{\sigma}_U^2, \widehat{\sigma}_D^2$)
Inicializar acumuladores: $S_U, S_D \leftarrow 0$; $C_U, C_D \leftarrow 0$
for $t = 0$ **to** $n - 1$ **do**
  if $M_{t+1} = U$ **then**
    $S_U \mathrel{+}= r_{t+1}$; $C_U \mathrel{+}= 1$
  else
    $S_D \mathrel{+}= r_{t+1}$; $C_D \mathrel{+}= 1$
  end if
end for
$\widehat{\mu}_U \leftarrow S_U / \operatorname{máx}(1, C_U); \quad \widehat{\mu}_D \leftarrow S_D / \operatorname{máx}(1, C_D)$
(Opcional) Varianzas por régimen: $\widehat{\sigma}_U^2, \widehat{\sigma}_D^2$ por fórmula muestral.
Chequeos: $C_U, C_D > 0$; magnitudes acordes con horizonte temporal y costos c. =0

Algorithm 5 Cálculo de $\bar{\mu}_t(m)$ y $r_t((m,i),a)$

1: **Entrada:** T (o T_t) con parámetros (α, β); medias (μ_U, μ_D); costo $c > 0$; estado $s = (m,i)$; acción a; etapa t

2: **Salida:** $\bar{\mu}_t(m)$; recompensa esperada $r_t((m,i),a)$ (si admisible)

3: Media condicional de retorno para el próximo tramo:

$$\bar{\mu}_t(U) \leftarrow T_t(U,U)\mu_U + T_t(U,D)\mu_D, \qquad \bar{\mu}_t(D) \leftarrow T_t(D,U)\mu_U + T_t(D,D)\mu_D.$$

4: Inventario siguiente: $i^+ \leftarrow f(i,a)$

5: Recompensa esperada inmediata (si a admisible en i):

$$r_t((m,i),a) \leftarrow i^+ \cdot \bar{\mu}_t(m) \; - \; c\,|i^+ - i|.$$

6: **Caso estacionario:** si $T_t \equiv T$, entonces $\bar{\mu}_t(m) \equiv \bar{\mu}(m)$ y $r_t \equiv r$. =0

Algorithm 6 Construir $\{P_{a,t}, \mathbf{r}_{a,t}\}_{a\in\mathcal{A}}$ con máscara de admisibilidad

1: **Entrada:** T (o T_t); $\bar{\mu}_t(U), \bar{\mu}_t(D)$; costo c; orden de estados $s_1 = (U,0)$, $s_2 = (U,1)$, $s_3 = (D,0)$, $s_4 = (D,1)$

2: **Salida:** $P_{\texttt{Buy},t}, P_{\texttt{Sell},t}, P_{\texttt{Hold},t}$; $\mathbf{r}_{\texttt{Buy},t}, \mathbf{r}_{\texttt{Sell},t}, \mathbf{r}_{\texttt{Hold},t}$

3: **Transiciones por acción y etapa.** Inventario siguiente $i^+ = f(i,a)$ y régimen siguiente distribuido según T_t. Así, por ejemplo:

$$P_{\texttt{Buy},t} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} 0 & T_t(U,U) & 0 & T_t(U,D) \\ 0 & 0 & 0 & 0 \\ 0 & T_t(D,U) & 0 & T_t(D,D) \\ 0 & 0 & 0 & 0 \end{pmatrix} \end{array},$$

$$P_{\texttt{Sell},t} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} 0 & 0 & 0 & 0 \\ T_t(U,U) & 0 & T_t(U,D) & 0 \\ 0 & 0 & 0 & 0 \\ T_t(D,U) & 0 & T_t(D,D) & 0 \end{pmatrix} \end{array},$$

$$P_{\texttt{Hold},t} = \begin{array}{c} \\ (U,0) \\ (U,1) \\ (D,0) \\ (D,1) \end{array} \begin{array}{c} \begin{array}{cccc} (U,0) & (U,1) & (D,0) & (D,1) \end{array} \\ \begin{pmatrix} T_t(U,U) & 0 & T_t(U,D) & 0 \\ 0 & T_t(U,U) & 0 & T_t(U,D) \\ T_t(D,U) & 0 & T_t(D,D) & 0 \\ 0 & T_t(D,U) & 0 & T_t(D,D) \end{pmatrix} \end{array}.$$

4: **Recompensas esperadas inmediatas por etapa** (inadmisibles $\to$ "n/a" o $-\infty$ si se maximiza):

$$\mathbf{r}_{\texttt{Buy},t} = \begin{bmatrix} \bar{\mu}_t(U) - c \\ \text{n/a} \\ \bar{\mu}_t(D) - c \\ \text{n/a} \end{bmatrix}, \quad \mathbf{r}_{\texttt{Sell},t} = \begin{bmatrix} \text{n/a} \\ -c \\ \text{n/a} \\ -c \end{bmatrix}, \quad \mathbf{r}_{\texttt{Hold},t} = \begin{bmatrix} 0 \\ \bar{\mu}_t(U) \\ 0 \\ \bar{\mu}_t(D) \end{bmatrix}.$$

5: **Máscara de admisibilidad (para optimalidad):** crear $\tilde{\mathbf{r}}_{a,t}$ sustituyendo "n/a" por $-\infty$.

6: **Caso estacionario:** si $T_t \equiv T$, entonces $P_{a,t} \equiv P_a$ y $\mathbf{r}_{a,t} \equiv \mathbf{r}_a$. =0

Algorithm 7 Evaluación de una política no estacionaria $\pi = \{\pi_t\}_{t=0}^{T-1}$ (forma matricial)

Entrada: $\{P_{a,t}, \mathbf{r}_{a,t}\}_{a,t}$; política $\pi_t(a \mid s_i)$ por etapa; pago terminal G; (opcional) $\gamma \in (0, 1]$

Salida: $\{\mathbf{v}_t^\pi\}_{t=0}^T$ tal que $\mathbf{v}_T^\pi = \mathbf{g}$ y $\mathbf{v}_t^\pi = \mathbf{r}_{\pi_t,t} + \gamma P_{\pi_t,t}\mathbf{v}_{t+1}^\pi$

Construir $\mathbf{g} = [G(s_1), G(s_2), G(s_3), G(s_4)]^\top$ y fijar $\mathbf{v}_T^\pi \leftarrow \mathbf{g}$

for $t = T - 1$ **to** 0 **do**

  $\Pi_{a,t} \leftarrow \mathrm{diag}(\pi_t(a \mid s_1), \ldots, \pi_t(a \mid s_4))$ (una por acción)

  $P_{\pi_t,t} \leftarrow \sum_a \Pi_{a,t} P_{a,t}$; $\mathbf{r}_{\pi_t,t} \leftarrow \sum_a \Pi_{a,t}\mathbf{r}_{a,t}$

  $\mathbf{v}_t^\pi \leftarrow \mathbf{r}_{\pi_t,t} + \gamma\, P_{\pi_t,t}\, \mathbf{v}_{t+1}^\pi$

end for

Devolver $\{\mathbf{v}_t^\pi\}_{t=0}^T$ =0

Lectura: Por etapa, el valor es *ganancia inmediata promedio* bajo π_t más *valor futuro esperado* (según $P_{\pi_t,t}$), con anclaje terminal $\mathbf{v}_T^\pi = \mathbf{g}$. Si no se usa descuento en finito–horizonte, tomar $\gamma = 1$.

Algorithm 8 Dinámica óptima finito–horizonte (backward induction)

Entrada: $\{P_{a,t}, \tilde{\mathbf{r}}_{a,t}\}_{a,t}$ (con $-\infty$ en inadmisibles); pago terminal G; (opcional) $\gamma \in (0, 1]$

Salida: valores óptimos $\{\mathbf{v}_t^*\}_{t=0}^T$ y política óptima no estacionaria $\{\pi_t^*\}_{t=0}^{T-1}$

Fijar $\mathbf{v}_T^* \leftarrow \mathbf{g}$ con $\mathbf{g} = [G(s_1), \ldots, G(s_4)]^\top$

for $t = T - 1$ **to** 0 **do**

  for cada estado $i \in \{1, \ldots, 4\}$ **do**

    $Q_{a,t}[i] \leftarrow \tilde{\mathbf{r}}_{a,t}[i] + \gamma\,(P_{a,t}\,\mathbf{v}_{t+1}^*)[i]$ para todas las acciones a

    $v_t^*[i] \leftarrow \max_a Q_{a,t}[i]$

    Elegir $a^\star \in \arg\max_a Q_{a,t}[i]$ y definir $\pi_t^*(s_i) := a^\star$

  end for

end for

Devolver $\{\mathbf{v}_t^*\}_{t=0}^T$, $\{\pi_t^*\}_{t=0}^{T-1}$ =0

Comentarios. (i) La política óptima depende de t porque el tiempo restante $T-t$ altera el peso del futuro. (ii) El pago terminal G permite modelar liquidación forzosa o penalizaciones por inventario al final (p. ej., $G((m, 1)) = -c_{\mathrm{liq}}$). (iii) Si se desea, γ puede fijarse en 1.

Algorithm 9 Mapa completo (horizonte finito) desde datos hasta política óptima

1: **Paso A (Datos → etiquetas)**: construir r_t y M_t con umbral θ

2: **Paso B (Transiciones)**: estimar T (o T_t) vía MLE/Laplace

3: **Paso C (Retornos por régimen)**: estimar μ_U, μ_D con r_{t+1} etiquetado por M_{t+1}

4: **Paso D (Recompensa por etapa)**: computar $\bar{\mu}_t(m)$ y $r_t((m,i),a)$

5: **Paso E (MDP por etapa)**: construir $P_{a,t}$ y $\tilde{\mathbf{r}}_{a,t}$ con máscara de admisibilidad

6: **Paso F (Terminal)**: definir G (p. ej., liquidación obligatoria o $G \equiv 0$)

7: **Paso G (Evaluación o solución)**:

- *Evaluación de una política dada* $\{\pi_t\}$: usar la recursión $\mathbf{v}_t^\pi = \mathbf{r}_{\pi_t,t} + \gamma P_{\pi_t,t}\mathbf{v}_{t+1}^\pi$ con $\mathbf{v}_T^\pi = \mathbf{g}$.
- *Óptimo finito–horizonte*: aplicar retroinducción (algoritmo anterior) para obtener $\{\pi_t^*\}$ y $\{\mathbf{v}_t^*\}$.

8: **Paso H (Chequeos)**: filas de $P_{a,t}$ suman 1; signos y magnitudes de recompensas vs. costos; validación por *residuo de Bellman* por etapa $\|\mathbf{r}_{\pi_t,t} + \gamma P_{\pi_t,t}\mathbf{v}_{t+1} - \mathbf{v}_t\|_\infty$. =0